



임베디드소프트웨어학과 · 캡스톤 프로젝트

자세 분류 알고리즘 비교 및 선정 근거

바른자세 · 3 주차 발표 — 공통주제화에 따른 알고리즘 차별화 전략

실행 사양 대비 성능 (execution spec. vs. performance) 기준으로 Random Forest 선정 근거를 문헌으로 검증한다

3 주차 발표 · 관련 논문 조사

발표자: 기안 외 1인

목차

01 문제 제기 · 차별화 전략

02 프로젝트 구조 · 연구 목표

03 포즈 추정 모델 비교

04 분류기 비교 : 핵심 근거

05 가장 가까운 선행 연구

06 최신 관련 사례

07 RF·XGBoost·LightGBM 교차비교

08 MLP(딥러닝) 비교 후보

09 최종 연구 방향 · 결론

10 참고문헌

문제 제기 : 왜 알고리즘으로 차별화해야 하는가

이번 학기 다수 팀이 듀얼캠 기반 책상 자세 모니터링이라는 유사한 주제를 채택하면서, 하드웨어 구성만으로는 더 이상 차별화가 어려워졌다. 그래서 차별화 지점을 하드웨어에서 자세 추정 알고리즘 자체로 옮긴다.



주제 공통화

듀얼캠 · 책상 자세 모니터링이
다수 조의 공통 주제가 됨 —
하드웨어 구성만으로는 차별화
불가



차별화 지점 재설정

" 어떤 포즈 추정 모델 + 어떤
분류기를 쓰느냐 " 가 실사용성
(백그라운드 상시 구동) 을
가른다



평가 기준


정확도 극대화가 아니라 " 실행
사양 대비 성능 " — 저사양
노트북에서 다른 작업과 동시
구동 가능한가



이번 발표 목표


관련 논문을 조사해 Random
Forest 선정 근거와 개선 방향
아이디어를 문헌으로 뒷받침

프로젝트 구조와 연구 목표



연구 목표

단순히 가장 정확한 알고리즘을 선택하는 것이 아니라, 기존 자세 분류 알고리즘을 적용한 뒤 성능과 연산 효율을 분석하고, 적절한 알고리즘을 개선하여 기존 모델과 개선 모델을 비교하는 것을 목표로 한다.



MoveNet Lightning

이미 잠정 채택 — 17 개 keypoint 기반 포즈 추정



Random Forest

관절 좌표 · 각도 · 거리 특징 분류에 잠정 채택



이번 조사의 역할

이 조합이 "저사양 노트북 백그라운드 상시 구동" 조건에 맞는지 문헌으로 검증

포즈 추정 모델 비교 : 정확도 vs 속도

모델	정확도	1,000 장 처리시간	Keypoint 수
PoseNet	97.6% (최고)	75.2 초	17 개
OpenPose	86.2%	643.5 초 (최장)	137 개
MoveNet Thunder	80.6%	140.0 초	17 개
MoveNet Lightning ★	75.1%	53.5 초 (최속)	17 개

③ Jo & Kim, Traitement du Signal, 2022 (IIEETA) — 원문 PDF 직접 확인 완료

MoveNet Lightning 은 OpenPose 대비 약 12 배 빠르며 , " 사람이 없는 이미지 " 에서도 낮은 오탐률 유지 (3 그룹 기준 71.5% 로 하락하는 구간은 참고 필요)

MoveNet Lightning 을 고른 이유

12×

OpenPose 대비 처리 속도 (IIEETA 2022)



저사양 CPU 에서 5 초 주기 백그라운드 상시 구동에 적합한 속도



TFLite 등 성숙한 온디바이스 배포 생태계 — 사전학습 모델 바로 활용 가능

분류기 비교 : 핵심 근거

① Toward Real-Time Posture Classification: Reality Check

Zhang et al., Electronics(MDPI), 2025

목적: 실시간 자세 분류에 값비싼 딥러닝이 정말 필요한지 CPU 단독 환경에서 검증하기 위해 고전 ML 과 LSTM(딥러닝) 의 속도 · 정확도를 비교한 논문 — 그 결과가 아래 수치다.

고전 ML(SVM·Gaussian NB·Random Forest·Neural Network) 이 CPU 단독 비교에서 **가장 느린 고전 분류기 (AdaBoost)조차 LSTM 보다 약 20 배 빠르면서도**, 최대 99% 정확도를 낼 수 있음을 원문 (Table 4) 으로 확인함.

주의: 이 논문의 속도 비교 (Fig.10) 에 RF 는 직접 포함되지 않음 — "RF 가 20 배" 가 아니라 " 고전 ML 계열이 20 배 " 로 정확히 인용

⑤ EAI (2021) — 관절 각도 특징 비교 (Kinect 관절각도 기반)

10-fold 교차검증 : SVM(RBF) 83.42% > Logistic Reg. 80.91% > RF 77.08% > kNN 76.98% > Naive Bayes 74.56%. RF 는 중위권 — "RF 가 항상 최고 " 라고 과장하지 않는다.

⑥ 휠체어 압력센서 (Sensors, 2021) — 반대 양상

압력센서 데이터 기준 RF 98.65% > SVM 95.96% 로 역전되지만 속도는 SVM 0.051 초 < RF 0.167 초로 SVM 이 더 빠르다 — 정확도 · 속도 우위는 데이터 · 모달리티마다 달라진다.

가장 가까운 선행 연구 : Weighted Random Forest

② Lee, Choi, Kim, "Classification Algorithm for Sitting Postures Using Weighted Random Forest", IET Image Processing, 2025

프로세스

카메라 입력 → 얼굴 · 어깨 좌표 / 각도 추출 → 특징 중요도 분석 → 특징별 가중치 적용 → Weighted Random Forest → 5 가지 자세 분류 (정상 / 숙임 / 기대기 / 좌우 기울임)

5 가지 착석 자세 (정상 / 숙임 / 기대기 / 좌우 기울임) 분류 정확도 · F1

0.983

가중치 없는 RF 96%→WRF 98% · 8 개 분류기 중 최고 , 최저 KNN(0.81) 대비 +0.17

발표 포인트: 저자가 결론에서 직접 제안한 " 후속 연구 방향 — depth-sensing camera 로 3D 데이터 수집 " 이 바른자세의 스테레오 카메라 설계와 정확히 일치한다. " 선행 연구가 미래 과제로 남긴 것을 우리는 구현했다 " 는 스토리로 활용.

선행 논문 vs 우리 프로젝트

구분	선행 논문	바른자세
카메라	단일 전면 2D	스테레오 Depth
특징 추출	얼굴 · 어깨 중심 좌표	전신 17 Keypoint
데이터 차원	2D 픽셀 좌표	3D 좌표 +Depth
개선 방식	Feature Weighting	Selection+Weighting +HP 최적화
오분류 원인	옷 · 배경색 유사 , 얼굴 기울임	전신 특징 + 깊이로 원천적 완화 가설

최신 관련 사례 : MoveNet 기반 자세 분류

④ Pawitra et al., "Automated ergonomic sitting postures detection for office workstation using XGBoost method", IAES Int. J. Artificial Intelligence, Vol.15 No.1, 2026.02

MoveNet Thunder 로 17 개 keypoint 추출 → 상반신만 정규화 → AdaBoost / XGBoost / MLP 비교 , 정상 / 비정상 2 분류 (참가자 30 명 , 유효 인스턴스 1,550 개).

↓ 아래 표 : 정상 / 비정상 착석 자세 2 분류 정확도 · F1 · ROC-AUC (참가자 30 명 · 유효 인스턴스 1,550 개 , 10-fold 교차검증 평균)

분류기	Accuracy	F1	ROC-AUC	비고
AdaBoost	0.894 ± 0.021	0.889 ± 0.022	0.950 ± 0.016	
MLP	0.918 ± 0.221	0.915 ± 0.024	0.960 ± 0.011	폴드 간 편차 매우 큼 — 불안정
XGBoost	0.930 ± 0.019	0.929 ± 0.019	0.974 ± 0.010	최고 · 가장 안정적

우리에게 남겨진 갭 : 이 논문은 우리와 같은 MoveNet 계열 (Thunder) 을 실제 자세 분류에 쓴 2026 년 최신 사례지만 , 비교군에 Random Forest 가 없다 (AdaBoost/XGBoost/MLP 만 비교) . 우리가 여기에 RF/WRF 를 추가로 비교하면 이 논문의 공백을 메우는 기여가 된다 . 저자도 " 상반신 키포인트만 사용 , 시점 · 가림 · 조명에 민감 " 을 한계로 명시 — 전신 17 키포인트 + 스테레오 깊이로 보완 가능하다는 가설 제시 .

RF·XGBoost·LightGBM: 선행연구 교차비교

팀원이 조사한 3 편을 표로 나란히 비교한다 — RF 가 항상 1 위는 아니므로 정직하게 비교한다.

알고리즘	선행연구 입력	주요 방법	주요 결과 / 의의	본 프로젝트 적용
② Random Forest	얼굴 · 어깨 좌표 / 각도 / 비율	변수중요도 기반 Weighted RF	5 개 자세 분류 RF 98%	기준모델 + Feature Selection·Weighting 개선
④ XGBoost	MoveNet 17 Keypoint	정규화 · 중심화 + XGBoost	Accuracy 93.0%±1.9%, F1 92.9%	MoveNet 기반 구조 유사
⑥ LightGBM	16 개 압력센서 수치	KNN·SVM·RF·DT·LightGBM 비교	실시간 모니터링 가능성 및 경량성 비교	정확도 + 추론시간 +CPU·RAM 비교

핵심: WRF 는 RF 계열이 가장 높고 (0.98·1 위), XGBoost 논문엔 애초 RF 비교군이 없으며, LightGBM 압력센서 사례는 LightGBM 이 근소 우위 (99.03%>98.65%) — 논문마다 RF 의 순위가 다르다.

결론 : "RF 가 절대적으로 가장 빠르고 정확하다 " 고 주장하지 않는다 . 대신 RF 성능을 객관적으로 검증한 뒤 , 동일 데이터 (MoveNet Keypoint+ 깊이) 로 XGBoost·LightGBM 과 직접 실측 비교해 최적화하는 것을 다음 단계 목표로 삼는다 .

MLP(딥러닝) 비교 후보 추가

RF·XGBoost·LightGBM 은 모두 트리 기반 ML — 팀원이 딥러닝 비교 축(MLP) 을 추가 조사, 원문에서 수치까지 검증

Reality Check 와 배치되지 않는 이유 : MLP 는 LSTM 과 달리 순환 구조가 없는 경량 피드포워드 신경망이다 (ConMLP 46.54M FLOPs vs GCN 2.5G FLOPs, Yoga MLP 는 12→10→8→6 의 초소형 구조) — " 비싼 딥러닝은 불필요 " 라는 결론과 배치되지 않는다 . 다만 RF 와 CPU 상에서 직접 비교한 검증은 아직 없어 , 최종 모델로 미리 정하지 않고 RF·XGBoost·LightGBM 과 동일 조건에서 공정 비교할 딥러닝 기준 모델로 추가한다 .

- | | |
|--|---|
| <p>⑦ Yoga Pose MLP (CIN, 2022)</p> | 관절각도 12 개 → MLP(은닉 10·8) → 요가자세 6 종 . 테스트 정확도 0.9958 (350 개 인스턴스) . 우리와 구조가 가장 유사 |
| <p>⑧ KeypointNet (Electronics, 2025)</p> | 지역 + 전역 Keypoint 특징을 MLP 로 결합해 분류 . MVSP 98.46%/HASP 96.52%/MSRA 99.48%. MLP 는 독립분류기가 아닌 구성요소 |
| <p>⑨ YOLOv8+Graph MLP (Discover AI, 2026)</p> | Graph MLP 도입으로 추론시간 0.23 초→0.08 초 , FPS 58→125 로 개선 . 향후 확장연구 (Graph MLP/GCN) 방향의 근거 |
| <p>⑩ ConMLP (Sensors, 2023)</p> | 경량 MLP 자기지도학습으로 NTU RGB+D 96.9%, 46.54M FLOPs — GCN 계열 (2.5G FLOPs) 보다 훨씬 가벼움 . 배경자료용 |

결론 : 우리의 차별화 지점

③ MoveNet Lightning 은 정확도 1 등은 아니지만 (75% 대) OpenPose 대비 12 배 빠르고 저사양 환경에 적합 — 우리 시나리오 (1 인 고정) 엔 속도가 더 중요

① 고전 ML(RF 포함 계열) 은 LSTM 대비 CPU 에서 약 20 배 빠르면서 최대 99% 정확도 가능 — 딥러닝 없이도 충분한 실시간 성능 확보

② Weighted RF 선행 연구가 남긴 "3D 깊이 카메라 " 과제를 스테레오 카메라로 이미 구현 중 — 가장 가까운 선행 연구의 다음 단계를 우리가 실현

④ MoveNet Thunder+XGBoost 최신 사례 (2026) 에는 Random Forest 비교군이 없음 — 우리가 RF/WRF 를 추가 비교하면 이 공백을 메우는 기여가 됨

종합 바른자세의 조합은 " 정확도 극대화 " 가 아니라 " 저사양 노트북에서 다른 작업과 동시 구동 가능한 실용적 실시간 시스템 " 을 목표로 한 의도적 선택

다음 단계: 3 주차 게이트 (카메라 캘리브레이션 + 노트북 CPU 기준 포즈 추정 성능 실측) 에서 문헌상의 속도 · 정확도 수치를 우리 실제 환경에서 검증한다.

참고문헌 (1/2)

- ① Zhang, H.; Gračanin, D.; Zhou, W.; Dudash, D.; Rushton, G. "Toward Real-Time Posture Classification: Reality Check." Electronics 2025, 14, 1876. *사용: p.6, p.11*
- ② Lee, J.; Choi, H.; Kim, J. "Classification Algorithm for Sitting Postures Using Weighted Random Forest." IET Image Processing 2025, 19, e70126. *사용: p.6, p.7, p.9, p.11*
- ③ Jo, J.; Kim, Y. "Comparative Analysis of OpenPose, PoseNet, and MoveNet Models for Pose Estimation in Mobile Devices." Traitement du Signal 2022, 39(1), 119-124. *사용: p.5, p.11*
- ④ Pawitra et al. "Automated ergonomic sitting postures detection for office workstation using XGBoost method." IAES Int. J. Artificial Intelligence 2026, 15(1), 506-514. *사용: p.8, p.9, p.11*
- ⑤ "Comparing the Performance of Different Classifiers for Posture Detection." EAI, 2021. *사용: p.6*

참고문헌 (2/2)

- ⑥ Ahmad, J.; Sidén, J.; Andersson, H. "A Proposal of Implementation of Sitting Posture Monitoring System for Wheelchair Utilizing Machine Learning Methods." Sensors 2021, 21(19), 6349.

사용: p.9

- ⑦ Thoutam, A. et al. "Yoga Pose Estimation and Feedback Generation Using Deep Learning." Computational Intelligence and Neuroscience 2022.

사용: p.10

- ⑧ Cao, Z. et al. "KeypointNet: An Efficient Deep Learning Model with Multi-View Recognition Capability for Sitting Posture Recognition." Electronics 2025, 14(4), 718.

사용: p.10

- ⑨ Tian, D.; Liu, B. "Human posture recognition model integrating YOLOv8 pose and graph multilayer perceptron." Discover Artificial Intelligence 2026, 6, 1043.

사용: p.10

- ⑩ Dai, C. et al. "ConMLP: MLP-Based Self-Supervised Contrastive Learning for Skeleton Data Analysis and Action Recognition." Sensors 2023, 23(5), 2452.

사용: p.10